

机器学习

第三讲: 决策树

顾小东

上海交通大学计算机学院




回忆一下目前为止学了什么？

线性回归模型

$$y = f(x) = \mathbf{w}^T \mathbf{x} + w_0$$

characterize the relationship
between one or more independent
variables and a target variable



回归 vs. 分类

机器学习

— 监督学习


— 回归

— 分类 (✓)

— ...


— 无监督学习

— 强化学习



Model the data points spread in $(d+1)$ -dim space.

回归: (predicts real-valued labels)





Model the boundaries that separate the data of different labels in d -dim space

分类: (predicts categorical labels)

分类问题

机器学习处理的主要任务




Sentiment analysis



我们从最简单的分类算法开始讲起

- 决策树
- 随机森林

回顾: 水果分类Hello World



回顾: 水果分类Hello World

分类 =


寻找一个决策边界，将特征空间划分成2个部分（每部分代表一个水果类型）



如何表示决策边界?

一个简单的线性函数?


如果数据分布是这样的呢？



- 非线性 (can not be linearly separated)
- 可能非数值 (e.g., “male”, “female”)

从线性到分段线性

如果数据分布是这样的呢？





- 非线性 (can not be linearly separated)
- 可能非数值 (e.g., “male”, “female”)
- 但是，沿着某些维度**局部线性可分**

决策树的基本思想

Divide
and
Conquer

- 分而治之

- 划分数据属性.
- 创建if-then规则




决策树: 通过一系列决策规则对数据进行分类。

模型结构

- 决策树包含三种类型的节点:

1. 根节点(**root node**)
2. 中间节点(**Internal nodes**)
3. 叶子节点(**Leaf nodes**, terminal nodes)



- ▷ 每个叶子节点对应一个类别标签
- ▷ 每个非叶子节点包含属性测试条件, 用来根据属性不同特征划分数据.




如何构建(训练)一棵决策树?

模型训练 – (构建决策树)

自顶向下分治学习

1. 构造一个根节点，包含整个数据集。
2. 选择一个最合适的属性
3. 根据选择属性的不同取值，将当前节点的样本划分成若干子集；
4. 对每个划分后的子集创建一个孩子节点，并将子集的数据传给该孩子节点；
5. 递归重复2~4直到满足停止条件。


ID	width	height	Type
1	5.2	8.0	lemons
2	6.7	9.8	lemons
3	7.2	7.5	orang
4	6.1	5.3	orang
5	4.1	6.5	lemons



关键问题

- 按照不同划分顺序，同一数据可以构建多种不同的树!


Q: 如何高效率的构建决策树?



A: 选择每个属性X的时候，尽可能**最大化**标签Y的**纯度**

决策树将数据逐步分割成越来越小的子集。最理想的情况是叶节点对应的样本属于同一类别(节点的标签纯净)。

Q: 如何选择属性以最大化标签的纯度?



A: 选择X以最大化**信息增益**、Gini系数等

每一种指标对应一种决策树构造算法

训练算法

按照不同的属性划分原则，有以下常见算法：

ID3 (基于信息增益)


CART (基于Gini Index)

C4.5 (基于信息增益率)

...

ID3算法


- 划分属性使最大化信息增益 (Information Gain)
 - 试着对每个属性进行划分, 看看哪个划分效果“最好”



- 评估样本的整体信息熵的降低程度

回顾: 熵 – 刻画一个数据集的不纯净度.

$$H(D) = - \sum_{k=1}^K p_k \log p_k$$



ID3算法


$$H(D) = -\sum_{k=1}^K \frac{|C_k|}{|D|} \log \frac{|C_k|}{|D|} \quad (|C_k|: \# \text{ samples of class } C_k \text{ in dataset } D)$$

$$H(D|A) = \sum_{i=1}^n \frac{|D_i|}{|D|} H(D_i) = -\sum_{i=1}^n \frac{|D_i|}{|D|} \left(\sum_{k=1}^K \frac{|D_{ik}|}{|D_i|} \log \frac{|D_{ik}|}{|D_i|} \right)$$

($|D_i|$: # samples whose attribute A is set to the i-th value in D; $|D_{ik}|$: #samples of class C_k in D_i)

$$\text{Gain}(D, A) = H(D) - H(D|A)$$


例子: 以下数据划分的信息增益是多少?



- 划分前(根节点)的熵: $H(D) = -\frac{49}{149} \log(\frac{49}{149}) - \frac{100}{149} \log(\frac{100}{149}) \approx 0.91$
- 划分后(叶节点)的平均熵: $H(D|A=1) = 0$, $H(D|A=2) \approx 1$
- $\text{IG}(D|A) \approx 0.91 - (\frac{1}{3} \cdot 0 + \frac{2}{3} \cdot 1) \approx 0.24 > 0$

举例

ID	width	height	Type
1	5.2	8.0	lemons
2	6.7	9.8	lemons
3	7.2	7.5	orang
4	6.1	5.3	orang
5	4.1	6.5	lemons



Step1 – 创建根节点

Step2 – 计算每个(子)数据集的熵.


lemon	orange
3	2

$$H(D) = - \frac{3}{5} \log \frac{3}{5} - \frac{2}{5} \log \frac{2}{5} = 0.97$$


举例

Step 3 – 对每个属性计算信息增益IG, 选择具有最大IG的属性

ID	width	Type
1	5.2	lemons
2	6.7	lemons
3	7.2	orang
4	6.1	orang
5	4.1	lemons




ID	height	Type
1	8.0	lemons
2	9.8	lemons
3	7.5	orang
4	5.3	orang
5	6.5	lemons



$$H = -\frac{1}{2}\log\frac{1}{2} - \frac{1}{2}\log\frac{1}{2} = 1$$

$$H = -\frac{2}{3}\log\frac{2}{3} - \frac{1}{3}\log\frac{1}{3} = 0.92$$

$$\begin{aligned}
 H(D \mid \text{width}) &= \frac{2}{5} H(D \mid \text{width} > 6.5) + \frac{3}{5} H(D \mid \text{width} < 6.5) \\
 &= \frac{2}{5} \times 1 + \frac{3}{5} \times 0.92 = 0.95 \\
 \text{Gain}(D \mid \text{width}) &= H(D) - H(D \mid \text{width}) = 0.97 - 0.95 = 0.02
 \end{aligned}$$



$$H = -1\log 1 - 0\log 0 = 0$$

$$H = -\frac{2}{3}\log\frac{2}{3} - \frac{1}{3}\log\frac{1}{3} = 0.92$$


$$\begin{aligned}
 H(D \mid \text{height}) &= \frac{2}{5} H(D \mid \text{height} > 7.5) + \frac{3}{5} H(D \mid \text{height} < 7.5) \\
 &= \frac{2}{5} \times 0 + \frac{3}{5} \times 0.92 = 0.55 \\
 \text{Gain}(D \mid \text{height}) &= H(D) - H(D \mid \text{height}) = 0.97 - 0.55 = 0.42
 \end{aligned}$$

举例

Step 4 – 将最大IG的属性赋给当前(根)节点。对每个属性取值扩展一个分支用于创建新节点。

ID	width	height	Type
1	5.2	8.0	lemons
2	6.7	9.8	lemons
3	7.2	7.5	orang
4	6.1	5.3	orang
5	4.1	6.5	lemons

Step 5 – 将数据集按选中的属性取值进行拆分，然后从数据集中移除该属性。



recursion

{1,2}

ID	width	height	Type
1	5.2	8.0	lemons
2	6.7	9.8	lemons

ID	width	height	Type
3	7.2	7.5	orang
4	6.1	5.3	orang
5	4.1	6.5	lemons

Step 6 – 对每个划分后的子数据集，重复2-5步直到满足停止条件（递归）



停止划分的条件

- 纯度
 - 叶子节点包含的样本均属于同一类
- 数据量过小
 - 叶子节点包含的样本数小于一个阈值
- 没有属性可分 (ID3)

算法优缺点

优点：

- 易理解，可解释性，便于可视化分析，
- 数据预处理要求低，
- 可以轻易处理非线性边界，
- 数据驱动，可以以任意精度拟合训练集.




算法优缺点


缺点：

- 容易过拟合

某些噪声样例总能被树涵盖并学习




(A) A partition of the data space




(B). The decision tree

data collection. If it is pruned, we obtain Fig. 11.10(c).




(A) A partition of the data space




(B). The decision tree

随机森林

- 将数据随机划分子集，各自构建决策树，将结果合并。
(三个臭皮匠，顶一个诸葛亮)



随机森林



-
1. Sampling a set of N samples from the original dataset, **putting them back after sampling**.
 2. Train a decision tree using the random dataset. For each node:
 - a. Randomly sample d attributes
 - b. Split nodes based on the selected attributes (e.g., information gain)
 3. Repeat 1~2 for k times
 4. Aggregate predictions by all decision trees, produce the final results by majority voting.
-

随机森林

优点:

- 往往比决策树更准确
- 训练速度快，容易并行化（训练时树与树之间是相互独立的）.
- 可以处理高维(feature很多)数据，并且不用做特征选择（因为特征子集是随机选择的）.
- 可以处理缺失属性.
- 结果易解释（i. e. , 在训练完后，能够给出哪些feature比较重要）.
- 在训练过程中，能够检测到feature间的互相影响。
- 对于不平衡的数据集来说，它可以平衡误差。
- ...

敲一敲代码

Tutorial: Decision Trees from Scratch with Python




What's Next?

Bayes Classifier

- A new perspective of machine learning and classification.
- Classify data by estimating posterior probability.
 - Bayes Decision
 - Classification using Bayes Net
 - Naïve Bayes

WHAT'S
NEXT?



NEXT